

HTW Berlin
Studiengang Angewandte Informatik, Master

Forschungsprojekt 1
Auf Wasserverbrauch basierende, preiswerte Sturz-
und Aktivitätserkennung für alleinstehende Senio-
ren

von Falko Benthin
Matrikelnr.: 0522617
Potsdam, 8. April 2013

Betreuung: Prof. Dr. Peter Hufnagl

Inhaltsverzeichnis

Abbildungsverzeichnis	3
1 Einführung	4
1.1 Hintergrund	4
1.2 Motivation	5
2 Aktuelle Entwicklungen	6
2.1 Beschleunigungssensoren, Tilt-Sensoren und Gyroskope	6
2.1.1 Vorteile	7
2.1.2 Nachteile	7
2.2 Visuelle Systeme	8
2.2.1 Vorteile	9
2.2.2 Nachteile	9
2.3 Akustische Sturzerkennungen	10
2.4 AAL-Systeme, Bewegungsmelder, Drucksensoren, RFID und andere	10
3 Systementwurf	12
3.1 Anforderungen	12
3.2 Hardware	12
3.3 Software	13
4 Sturz und Aktivitätserkennung	15
4.1 Fallbeispiele	15
4.2 Idee	15
4.3 Algorithmus Aktivitätserkennung	16
4.4 Abweichendes Verhalten erkennen	17
4.5 Abwesenheit	19
5 Alarmkaskade	20
6 Test	22
6.1 Probleme in der Praxis	24
7 Fazit und Ausblick	25
Abkürzungsverzeichnis	26
Glossar	27
Literaturverzeichnis	28

Abbildungsverzeichnis

3.1	Hardwarekomponenten	13
3.2	Klassendiagramm Sturzerkennung	14
4.1	Flussdiagramm Monitoring	16
4.2	Flussdiagramm Sturzerkennung	19
5.1	Flussdiagramm Alarmkaskade	21
6.1	Wasserverbrauch während des aufgezeichneten Zeitraums	22
6.2	Wahrscheinlichkeit der Wasserentnahme an Wochentagen	23
6.3	Wahrscheinlichkeit der Wasserentnahme an Wochenenden	23

1 Einführung

1.1 Hintergrund

Innerhalb der nächsten Jahre wird der Anteil der Menschen über 65 Jahre in unserer Gesellschaft stark zunehmen. Das Bundesamt für Statistik geht in seiner 12. koordinierten Bevölkerungsvor-
5 ausberechnung davon aus, dass der Anteil der über 65jährigen im Jahr 2040 circa ein Drittel der deutschen Gesamtbevölkerung ausmacht [1]. In anderen Industrienationen ist eine ähnliche Entwicklung zu erwarten. Von den „jungen“ Alten (65 bis 70 Jahre) werden bereits ungefähr 20 Prozent allein leben. Diese Zahl wird bei den Männern mit zunehmendem Alter fast konstant bleiben. Bei den Frauen erhöht sich aufgrund der unterschiedlichen Lebenserwartungen der
10 Anteil der Alleinlebenden auf 56 Prozent bei den über 80jährigen [2].

Stürze und die Angst vor Stürzen spielen in der Altersgruppe 65+ eine große Rolle. Studien von Masud und Morris [3] und anderen [4] zeigen, dass circa ein Drittel der Betroffenen mindestens einmal pro Jahr stürzt. In vielen Gesellschaften entfällt auf Stürze Älterer ein hoher Kostenfaktor im Gesundheitswesen [5].

15 Während die meisten Stürze als harmlos einzustufen sind, ziehen fünf bis zehn Prozent der Stürze Älterer ernsthafte Folgen nach sich [6]. Das sind neben Knochenbrüchen und Kopfverletzungen lange Krankenhausaufenthalte, bleibende Einschränkungen und Tod, aber auch psychische Probleme [7, 8, 9]. So fürchtet sich etwa ein Drittel derer, die einen Sturz erlebten, vor weiteren Stürzen. Sie bewegen sich weniger, was zu Immobilität, Abhängigkeit, Problemen beim Balance-
20 halten, Gehen und der Wahrnehmung, Vereinsamung und Depressionen führen kann [4].

Gründe für das Fallen sind vielfältig. Die Ursachen können Krankheiten wie Diabetes, Parkinson, Depression, Inkontinenz oder Alzheimer oder physische Probleme wie eine schwach ausgeprägte Muskulatur, nachlassende Sehkraft, Verwirrung, Fußprobleme oder Untergewicht sein. Weitere Risikofaktoren sind inaktives Verhalten, Medikamenteneinnahmen und damit einhergehende
25 Neben- oder Wechselwirkungen (z.B. verzögerte Reaktionen, niedriger Blutdruck), übermäßiger Alkoholgenuß, schlechtes Schuhwerk oder ungünstige Umgebungen mit glatten Fußböden oder zu wenig Licht [4].

Älteren, die in Gesellschaft anderer leben, wird nach Stürzen meist schnell geholfen. Alleinlebende, die nach einem Sturz aufgrund ihrer Verletzungen oder körperlichen Gebrechen nicht in
30 der Lage sind, selbst aufzustehen und Hilfe zu holen, bleiben oft mehrere Stunden und länger unentdeckt. Laut Gurley et al. werden pro Jahr 3,2 Prozent der Alleinlebenden über 65 Jahre tot oder hilflos in ihren Wohnungen aufgefunden[10]. Bei schweren Verletzungen wie Hüftbrüchen führt das häufiger zu längeren Krankenhausaufenthalten und sogar zum Tod als bei Gleichaltrigen, denen bereits kurze Zeit nach dem Sturz geholfen wird. Wild et al. stellten fest, dass die
35 Hälfte der gestürzten Senioren, die lange hilflos auf dem Boden liegen, innerhalb eines halben

Jahres versterben [11]. Auch die psychischen Einschränkungen nehmen proportional zur Dauer der erlebten Hilfslosigkeit zu [12, 13, 14].

1991 stellten Lord und Colvin [15] ein aus Videoüberwachung und Beschleunigungssensoren bestehendes System vor, das helfen sollte, Stürze automatisch zu erkennen. In den darauf folgenden
40 Jahren, besonders ab 1998, nahmen sich Wissenschaftler verschiedener Länder des Themas an und entwickelten verschiedene Technologien, mit denen Stürze rechtzeitig erkannt und Helfer alarmiert werden[16].

1.2 Motivation

Laut dem Deutschen Institut für Wirtschaftsforschung e.V. betrug die Armutsgefährdungsquote
45 für über 65jährige in Deutschland bereits zehn Prozent [17]. Die momentane Wirtschaftsministerin von der Leyen geht gemäß der Tageszeitung „Bild am Sonntag“ unter Berufung auf einen siebenseitigen Brief an die Junge Gruppe der Unionsfraktion davon aus, dass im Jahr 2030 mehr als ein Drittel der deutschen Rentner armutsgefährdet sein wird [18]. Dazu kommt das Problem fehlenden Pflegepersonals.

50 Es ist davon auszugehen, dass sich diese Personengruppe keine kostspieligen Sturz- und Aktivitätserkennungssysteme leisten können wird und sie daher einem höheren Risiko ausgesetzt sein wird als wohlhabende Gleichaltige. Das wird zusätzlich durch das Problem mangelnden Pflegepersonals verschärft. Die Bertelsmann-Stiftung prognostiziert in ihrem „Pflegereport 2030“, dass
55 in circa 15 Jahren circa eine halbe Million Vollzeitpflegekräfte fehlen werden [19]. Das bedeutet, dass die Betreuung zu großen Teilen auf den Schultern Angehöriger lasten wird, wie es auch heute schon zu 70 Prozent der Fall ist [20].

Mit der stetig zunehmenden Zahl alleinlebender Älterer steigt auch der Bedarf an preiswerten Monitoring-Lösungen, mit deren Hilfe Familie, Freunde oder Nachbarn im Ernstfall informiert werden. In dieser Arbeit wird versucht, ein System zu konzipieren, das weniger als 100 Euro kostet
60 und den Wasserverbrauch als Kriterium für das Wohlergehen alleinlebender Senioren nutzt.

2 Aktuelle Entwicklungen

Um festzustellen, ob alleinlebende Personen fortgeschrittenen Alters wohlauf sind, wurden innerhalb der letzten Jahren verschiedene Technologien entwickelt. Es gibt Systeme, die sich darauf konzentrieren, Stürze zu erkennen und Angehörige oder Pflegepersonal zu informieren. Ferner
65 gibt es Technologien aus dem Bereich Ambient Assisted Living (AAL), die Abweichungen in den Aktivitäten des täglichen Lebens erfassen.

Bei den Sturzerkennungen sind Systeme zu unterscheiden, die am Körper getragen werden (z.B. Beschleunigungssensoren und Gyroskope) oder die in der häuslichen Umgebung der alleinlebenden Person integriert werden. Zur letzten Gruppe gehören beispielsweise Videoüberwachung, Mikrofone oder Sensoren, die empfindlich sind für Bewegungen, Druck, Änderungen der Temperatur
70 und Luftfeuchtigkeit oder die den Verbrauch von Energie und anderen Ressourcen auswerten. Die einzelnen Systeme sollen im Folgenden kurz vorgestellt werden.

Ein Sturz lässt sich in drei Phasen unterteilen:

- Bewegungen vor dem Sturz mit hohen Geschwindigkeiten, rascher Änderung der Körperhaltung oder freier Fall
75
- der Aufprall selbst mit hoher Beschleunigung bzw. rapider Änderung der Beschleunigung und
- Endposition des Körpers und evtl. reduzierte Aktivität nach dem Aufprall

Am Körper getragene Systeme, Videoüberwachung und akustische Sturzerkennungen versuchen
80 alle oder einzelne Phasen zu interpretieren. Wenn das gelingt, kann schnell Hilfe herbeigerufen werden. Systeme, die das Verhalten analysieren, sind dazu oft nicht in der Lage.

2.1 Beschleunigungssensoren, Tilt-Sensoren und Gyroskope

Beschleunigungssensoren und Gyroskope sind in der Sturzerkennung sehr beliebt. Ihnen allen ist
85 gemein, dass sie am Körper getragen werden. Mögliche Stellen sind Kopf, Brust, Taille, Oberschenkel, Oberarm und Handgelenk.

Hwang et al. entwickelten 2004 ein System, das aus Beschleunigungssensor, Tilt-Sensor und Gyroskop bestand und Daten via Bluetooth übertrug. Ereignisse, bei denen der Tilt-Sensor ausschlug und der Beschleunigungssensor einen Schwellwert überschritt, wurden als Sturz erkannt. Das System wartete anschließend zehn Sekunden, ob sich der Träger wieder bewegt. Wenn das nicht
90 der Fall war, wurde ein Alarm ausgelöst [21].

Wie Hwang verwendeten viele andere Schwellwerte, um Stürze zu identifizieren, beispielsweise Chen et al. [22], Kangas et al. [23] oder Srinivasan et al. [24]. Mehrere Forschungen beschäftigen sich damit, wie Sturzgefährdeten das Anlegen der Sensoren erspart werden kann. Bourke et al. entwickelten eine Weste mit Taschen für den Sensor [25, 26], die Wissenschaftler um
95 Prado-Velasco stellten ein Pflaster mit Beschleunigungssensor vor („ISIS“), das direkt am Körper getragen wird und auch unter der Dusche nicht abgenommen werden muss [27]. Niazmand et al. integrierten acht Beschleunigungssensoren in einen Pullover [28] und Sim et al. verfrachteten die Sensorik in die Sohle eines Schuhs [29].

Überwogen in der Vergangenheit Systeme, die von einem Sturz ausgingen, sobald die Messungen
100 der Beschleunigungssensoren einen bestimmten Schwellwert überschritten, sind in den letzten Jahren zunehmend Systeme vorgestellt worden, die auf Mustererkennungen wie Bayesschen Netzen, Hidden Markov Modellen, (One Class) Support Vector Machine s (Support Vector Machine) und neuronalen Netzen basieren, beispielsweise von Cheng et al.[30], Huang et al. [31] und Yuwono et al. [32].

105 2.1.1 Vorteile

Auf Beschleunigungssensoren basierende Sturzerkennungssysteme sind verglichen mit anderen Systemen recht preiswert und erfordern nur moderate Rechenkapazitäten. Sie benötigen keine aufwändigen Installationen in Wohnungen und sind nicht auf einen bestimmten Überwachungsbereich beschränkt. Mit den am Körper getragenen Sensoren ist es nicht nur möglich, einen
110 erfolgten Sturz zu erkennen, sondern auch, Stürze vorherzusagen. Tamura et al. entwickelten ein System mit Airbags, das einen Sturz 300 ms früher erkennt, als der Träger auf dem Boden aufschlägt und Kopf und Hüfte schützt [33]. Nyan et al. gelang es, den Sturz 700 ms vor dem Aufprall zu erkennen [34].

Werden die Beschleunigungssensoren und die Rechenkapazitäten der immer häufiger anzutreffenden Smartphones für die Fallerkennung genutzt, kann ein Pflege- oder Rettungsdienst auch
115 informiert werden, wenn der Träger außerhalb seiner Wohnung stürzt. Verfügt das Smartphone über GPS, kann es die Position des Trägers an entsprechende Stellen übermitteln [35].

2.1.2 Nachteile

Sturzerkennungen mit Beschleunigungssensoren gehen mit vielen Fehlalarmen (etwa bei Sprüngen, Plumpsenlassen beim Hinsetzen, Stolpern, Treppenbenutzung) einher, die bei Trägern und
120 Pflegepersonal zu Unmut führen können. Bagala et al. verglichen verschiedene Accelerometer-basierte Sturzerkennungen und stellten fest, dass deren Algorithmen täglich zwischen drei und 85 Fehlalarme auslösten [36].

Daher versuchen viele Entwicklungen, die Zahl der Fehlalarme mit mehr oder weniger kreativen
125 Methoden zu minimieren. Srinivasan et al. nutzen zusätzliche Infrarotsensoren, um zu prüfen ob sich eine Person nach einem Sturz noch bewegt [24]. Sposaro und Tyson sowie Abbate et al. analysieren ebenfalls die Sekunden nach einem gemeldeten Sturz, um über eine Alarmmeldung zu entscheiden [37, 38].

Estudillo-Valderrama et al. versuchten, die Sensorik zu personalisieren [39]. Nocua et al. stellten
130 dem Beschleunigungssensor zusätzliche Sensoren zur Seite, die Herzfrequenz, Hauttemperatur
und -widerstand messen [40]. Einen ähnlichen Weg beschritten Nguyen et al. [41]. Bianchi et
al. nutzten ein zusätzliches Barometer und gingen davon aus, dass sich der Luftdruck spürbar
verändern sollte, wenn eine Person zu Boden geht [42, 43]. Auch Tolkiehn et al. bezogen den
Luftdruck in ihre Betrachtungen mit ein [44].

135 Ghasemzadeh et al. verbanden ihre Versuchspersonen mit sieben Sensoren (Taille, Oberschenkel,
Unterschenkel, Handgelenke) [45], Gjoreski befestigten Sensoren an Brust, Taille, Oberschenkeln
und Fußgelenken [46] und Nyan et al. brachten ihre Sensoren an Oberkörper und Oberschenkeln
an [34], um die Genauigkeit zu erhöhen. Chang et al. bestückten ihre Probanden an Taille und
Fußgelenken mit Beschleunigungssensoren, um Fehlalarme beim Treppensteigen oder Gehen auf
140 schrägen Ebenen zu eliminieren [47]. Forscher, die neuronale Netze oder SVMs einsetzen, schlagen
Fehlalarme der Trainingsmenge für Tätigkeiten des alltäglichen Lebens zu [31].

Bagala et al. und Klenk et al. merkten an, dass die Personen, die Sturzerkennungen mit Accelerometers
trainieren, immer auf einen weichen Untergrund fallen oder dämpfende Kleidung tragen,
was zu anderen Messwerten führt, als wenn sie auf Stein oder Fliesen fallen würden. Ferner sind
145 simulierte Stürze immer geplant und spiegeln nicht die intuitiven Reaktionen wirklich Betroffener
wider [36, 48].

Da Systeme mit Beschleunigungssensoren am Körper befestigt werden müssen, erfordern sie
hohe Konzentration und Disziplin. Oft werden sie zum Schlafengehen oder Duschen abgelgt und
später vergessen. Viele Systeme sind für andere Menschen sichtbar und könnten den Träger
150 stigmatisieren.

Weitere Probleme bereitet die Energieversorgung. Die Sensoren sollen leicht und bequem zu
tragen sein, was leistungsstarke Akkus ausschließt. Die meisten Systeme funktionieren mit einer
Akkuladung ein bis zwei Tage, bevor sie wieder aufgeladen werden müssen.

Chen et. al kritisierten, dass nicht alle Funkübertragungstechniken zuverlässig arbeiten und
155 schwerlich alle Sturzzenarien in der Trainingsphase berücksichtigt werden können [22]. Selbst
wenn die Funktechnologie zuverlässig ist, etwa Bluetooth, Wlan oder Zigbee, hat sie oft nur eine
bestimmte Reichweite. Viele Sensoren übertragen ihre Messwerte an eine externe Recheneinheit.
Verlässt der Träger den Sende- und Empfangsbereich, werden Stürze nicht mehr erkannt.

2.2 Visuelle Systeme

160 Optische Sturzerkennungen bilden neben den Systemen mit Bewegungsmeldern die zweite große
Gruppe. Sie bestehen meist aus einer oder mehreren Kameras, die an der Decke oder Zimmer-
wand befestigt sind. Neben den Kameras sind auch leistungsfähige Rechner nötig, auf denen
die Bildverarbeitung durchgeführt wird. Die meisten Systeme subtrahieren den Hintergrund, um
Menschen „freizustellen“ und besser zu erkennen.

165 Nait-Charif und McKenna zeichneten eine Ellipse um den erkannten menschlichen Körper und
erfassten Stürze, indem sie die Lage der Ellipse auswerteten [49]. Eine den Körper einschließende

Ellipse wählten auch Foroughi et al., Liao und Huang, Shoaib et al. sowie Yu et al. für ihre Sturzerkennungssysteme [50, 51, 52, 53]. Foroughi et al. verfolgten zusätzlich Änderungen der Kopfposition. Shoaib et al. selektierten Kopf und Füße und erstellten Kopf-Boden-Blöcke, mittels
170 deren Höhe sie Stürze erkannten. Foroughi et al. erstellten auch spatio-temporale Datenbanken und ermittelten, wo sich Personen bewegen und wo nicht. Um die erfassten Bilder auszuwerten, reduzierten sie deren Features mit Eigenräumen [54, 55].

Miaou et al. verwendeten eine MapCam, die 360°-Szenerien überblickte, zeichneten ein Rechteck um Personen im Raum und analysierten das Verhältnis von dessen Höhe und Breite [56]. Jansen
175 und Deklerck nutzten eine 3D-Kamera und führten Inaktivitätszonen ein. Wenn sich eine Person in einer solchen Zone hinlegte, etwa ein Bett oder Sofa, wurde kein Alarm ausgelöst. Anders verhielt es sich bei Personen, die außerhalb der Inaktivitätszonen als liegend klassifiziert wurden [57].

Die Inaktivitätszonen wurden von etlichen anderen übernommen, z.B. Lv [58]. Anderson et al.
180 reduzierten erkannte Personen auf Silhouetten, zogen ebenfalls einen Rahmen um sie und berechneten permanent das Verhältnis der Kanten [59]. Einen ähnlichen Ansatz wählten Nasution und Emmanuel, die jedoch nicht das Verhältnis der Kanten, sondern den Winkel zwischen dem letzten Rahmen der stehenden und dem aktuellen Rahmen der sitzenden, hockenden, knieenden oder liegenden Person berechneten [60].

185 In der optischen Sturzerkennung setzen sich zunehmend 3D-Kameras oder aus mehreren Kameras bestehende Installationen durch, die 3D-Bilder ermöglichen. Diraco et al. und Leone et al. verbauten eine Time-of-flight-Kamera, die Tiefenbilder erzeugt und berechneten den Abstand zwischen Körper-Centroid und Boden [61, 62].

Andere arbeiteten mit mehreren 2D-Kameras. Lee und Chung berücksichtigten ebenfalls die
190 Tiefe, um Stürze genauer erkennen zu können [63]. Auvinet et al. und Anderson et al. [64, 65, 66] zogen die Voxel-Verteilung entlang der vertikalen Achse zur Sturzerkennung heran. Bourke et al. nutzten die „Personen-Blobs“, um die Geschwindigkeit des Kopfes zu verfolgen [67]. Yu et al. und Nghiem et al. analysierten Änderungen des Körper-Centroids [68, 69, 70]. Nyan et al. versahen ihre Probanden mit reflektierenden Markern an Bauch, Taille, Oberschenkel und Knie.
195 Sie beobachteten den Winkel zwischen Torso und Oberschenkel, um Stürze vorauszusagen [71].

2.2.1 Vorteile

Kameras sind recht preiswert und einfach zu installieren. Sie lassen sich nicht nur nutzen, um Stürze zu erkennen, sondern auch, um sie zu dokumentieren und später auszuwerten. Kame-
200 ras werden einmal installiert und sind später immer verfügbar. Die sturzgefährdeten Personen brauchen sich nicht um sie kümmern und können sie nicht vergessen.

2.2.2 Nachteile

Mit optischen Sturzerkennungen lassen sich nur vorher festgelegte Räume überwachen. Viele Patienten sehen sich auch in ihrer Privatsphäre eingeschränkt und wollen nicht permanent von

Kameras erfasst werden. Oft ist teure, leistungsfähige Rechentechnik nötig, um die von den
205 Kameras erfassten Bilder auszuwerten. Werden mehrere Kameras eingesetzt um ein 3D-Bild zu
erzeugen, müssen diese aufwändig synchronisiert werden [63].

Wenn Ältere allein leben, sind sie oft gezwungen, in kleinere Wohnungen umzuziehen. Wenn
sie viele Möbel mitbringen, kann das zu vollgestopften Zimmern und damit zu vielen „blin-
den Flecken“ führen. Diese müssten durch zusätzliche Kameras erfasst werden, was zusätzliche
210 Rechentechnik erfordert. Wechselnde Lichtverhältnisse können zu Fehlalarmen führen und bei
2D-Systemen ist es schwer, statische Modelle zu erzeugen, die unübliche von üblichen Ereignis-
sen unterscheiden [49]. So ist es beispielsweise möglich, dass Stürze erkannt werden, wenn sich
Personen hinsetzen oder unter dem Schrank nach heruntergefallenen Gegenständen stochern
[57]. Um Fehlalarme zu reduzieren, personalisierten Miaou et al. und Huang et al. ihr System
215 mit Größe, Gewicht und Krankengeschichte der zu überwachenden Personen [56, 72].

Um den Problemen der mangelnden Privatsphäre und erforderlichen teuren Rechentechnik zu
begegnen, schlagen Belbachir et al. und Humenberger et al. ereignisbezogene oder „bioinspirierte“
optische Erfassungssysteme vor. Diese haben eine geringe Auflösung, einen geringen Energiever-
brauch und erfassen nur relative Änderungen der Lichtverhältnisse. So fallen weniger Daten an,
220 die sich leichter auswerten lassen [73, 74, 75].

2.3 Akustische Sturzerkennungen

Mit der Sturzerkennung mittels Mikrofonen beschäftigten sich nur sehr wenige. Die Systeme
gelten als unzuverlässig, da Mikrofone oft krude, schwer interpretierbare Daten erzeugen [63].
Nichtsdestotrotz präsentierten Popescu et al. 2008 eine Installation aus einem vertikalem Mikro-
225 fonarray und einem Bewegungsmelder. Die in unterschiedlicher Höhe angebrachten Mikrofone
sollten Fehlalarme vermeiden. Erfasste das System einen Aufschlag und konnte der Bewegungs-
melder in der anschließenden Minute keine Aktivität feststellen, wurde ein Alarm ausgelöst.
Haustiere könnten bei einem akustischen System problematisch sein [76, 77].

Litvak et al. kombinierten Geräusche mit Bodenvibrationen [78]. Li et al. ersetzen Popescus
230 lineares Mikrofonarray durch ein zirkulares Array aus acht jeweils 25 cm voneinander entfernten
Mikrofonen, das in einer Höhe von 1,5 m installiert war und verfeinerten dessen Erkennungsrate
mittels Beamforming [79, 80].

2.4 AAL-Systeme, Bewegungsmelder, Drucksensoren, RFID und andere

235 Um zu prüfen, ob es einem alleinlebenden Senior gut geht, gibt es neben den „großen“ Sturzerken-
nungssystemen noch viele andere originelle Lösungen. Diese erkennen zum Teil nicht nur Stürze,
sondern auch abweichendes Verhalten, wodurch sich mittelfristig Änderungen der geistigen und
körperlichen Fähigkeiten erfassen lassen. Mit Hilfe dieser Systeme ist es zudem möglich, Pflege-
dienste und Angehörige zu informieren, wenn keine Aktivitäten feststellbar sind, etwa wenn der

240 Betroffene während einer Ruhephase verstorben ist oder sich aus einem anderen Grund nicht mehr bewegt.

Rangarajan et al. entwarfen Fußbodenbeläge mit Drucksensoren [81]. Rimminen et al. integrierten RFID-Technologie in den Fußboden [82]. Anders als Beläge mit Drucksensoren reagierten diese nicht auf Möbel oder ungewöhnliche Lastenverteilung, machten es aber erforderlich, dass der
245 Sturzgefährdete ebenfalls mit RFID-Technologie ausgestattet ist.

Ariani et al. verbauten in einer Wohnung Infrarotsensoren und Drucksensoren an Schwellen, Bett, Stühlen, Sofa sowie vor Dusche und Toilette. Sie gehen davon aus, dass immer ein Drucksensor oder ein Infrarotsensor aktiv ist. Bewegt sich die Person, reagiert der Infrarotsensor, sitzt sie auf dem Sofa oder liegt im Bett, registriert es der Drucksensor. Wird 15 Minuten lang keine
250 Aktivität erfasst, etwa weil eine Person gestürzt ist und sich nicht mehr bewegen kann, wird ein Alarm ausgelöst [83]. Tao et al. steckten mehrere Drucksensoren in Schuhe, um einen Sturz und die Sturzrichtung zu erkennen [84]. Popescu et al. verbauten einen vertikalen Array passiver Infrarotsensoren an der Wand mit dem sie menschliche Aktivitäten verfolgten [85].

Medjahed et al. nutzten ein aus physiologischen Sensoren, Infrarotsensoren, Mikrofonen, Verbrauchs- und Zustandssensoren bestehendes Set, um das Verhalten von Personen auszuwerten [86]. Aviles-Lopez et al. setzten ebenfalls auf eine Sensor-Infrastruktur, die aus Bewegungsmeldern, Mikrofonen, RFID-, Verbrauchs- und Beschleunigungssensoren bestand und Bewegungen und Positionen einer Person in der häuslichen Umgebung mittels der Stärke eines WLAN-Signals berechnete und Personen über ein Smartphone Verhaltenshinweise gab, z.B. an die Medikamenteneinnahme er-
260 innerte [87].

Toffola et al. nutzten eine ähnliche Konfiguration, ergänzten diese aber noch um einen Roboter, den das Pflegepersonal steuern konnte. Wurde ein abweichendes Verhalten gemeldet, ließ sich mit Hilfe des Roboters prüfen, ob die alleinlebende Person Hilfe brauchte [88].

Zouba et al. analysierten Verhalten mit Sensoren, die registrierten, ob eine Person Strom und
265 Wasser verbraucht oder Möbel benutzt und zusätzlichen Kameras, um Bewegungen zu verfolgen [89]. Amft und Lombriser versahen sogar Gegenstände des täglichen Lebens wie Bücher oder Kochutensilien mit Sensoren und konnten anhand deren Messdaten Rückschlüsse auf die Aktivitäten der Nutzer ziehen, z.B. Tee kochen etc. [90].

3 Systementwurf

270 3.1 Anforderungen

Die auf dem Wasserverbrauch basierende Sturz- und Aktivitätserkennung soll nicht nur preiswert sein, sondern sich auch ohne großen Aufwand in die häusliche Umgebung der Betroffenen installieren lassen. Weitere wichtige Anforderungen sind:

- leichte Bedienbarkeit
- 275 • das Verhalten des Seniors wird selbstständig erlernt
- Verhaltensänderungen werden automatisch übernommen
- das System berücksichtigt Abwesenheiten des Seniors
- ein Hilferuf kann manuell ausgelöst werden

3.2 Hardware

280 Heutige Sturz- und Aktivitätserkennungen kosten schnell mehrere Hundert Euro, komplette AAL-Systeme schlagen mit 3.500 Euro bis 5.000 Euro zu Buche [91]. Demgegenüber stehen Untersuchungen von Govercin et al., dass selbst viele Ältere mit einem teils erheblichen Sturzrisiko nicht bereit sind, in ein optisches oder tragbares Sturzerkennungssystem zu investieren. Govercin et al. befragten 22 Personen zwischen 50 und 85 Jahren, die sie in Gruppen mit geringem, er-
285 heblichem oder hohem Sturzrisiko einteilten. Gerade mal 38 Prozent der Befragten waren bereit, einmalig in ein tragbares System zu investieren, 13 Prozent würden sich eine optische Sturzerkennung zulegen. Als Investitionssummen wurden Beträge zwischen 100 Euro und 1.500 Euro genannt [92].

Die hier vorgestellte, sich auf den Wasserverbrauch stützende Verhaltensüberwachung basiert auf
290 einem Raspberry Pi (RPi) Model B [93], einem Arduino Uno [94], einem Flusssensor und einer USB-Webcam mit Mikrofon 3.1.

Der Raspberry Pi ist ein 85.60mm x 56mm x 21mm großer und 45 Gramm schwerer Einplatinencomputer mit einem Broadcom SoC BCM2835. Dieser enthält einen ARM11-Prozessor mit Gleitkommaarithmetik, der mit 700 MHz getaktet ist und eine leistungsfähige Videocore 4 GPU.
295 Der RPi verfügt über 256 MB RAM (neuere Modelle 512 MB) und zahlreiche Schnittstellen, z.




Abbildung 3.1: Raspberry Pi, Arduino Uno, Flussensor und Webcam bilden eine preiswerte Aktivitätserkennung

B. Ethernet, USB 2.0, HDMI, Audio Out, General Purpose Input/Output (GPIO) und einen Slot für SD-Karten.

Der Arduino Uno ist ein Microcontrollerboard, das auf einem ATmega328 basiert. Es verfügt über 14 digitale Ein-/Ausgabepins, sechs analoge Input-Pins, einen keramischen Resonator für eine Frequenz von 16 MHz, 32 KB Flash-Speicher und 2 KB SRAM.

Der Flusssensor enthält einen kleinen Rotor, der sich zu drehen beginnt sobald Wasser fließt. Ein integrierter Hall-Sensor registriert die Drehungen und liefert Werte zwischen 0 und circa 20.000.

Der Microcontroller liest die Werte des Flusssensors aus und überträgt sie via USB an den RPi. Neben dem Arduino hängen noch ein WLAN-Stick und eine USB-Webcam am RPi. Die Webcam ist so zu positionieren, dass sie den zentralen Lebensraum der zu überwachenden Person möglichst umfassend erfasst. Sie übernimmt später zwei Aufgaben: im Alarmfall erstellt sie Fotos, die an Angehörige oder den Pflegedienst versandt werden und sie dient mit ihrem Mikrofon als sprachgesteuerte Nutzerschnittstelle, da der RPi weder über ein Display noch über eine Tastatur verfügt.

Da die USB-Ports des RPi selbst mit einem leistungsfähigem USB-Netzteil nicht genügend Energie für alle Komponenten bereitstellen, war ein zusätzlicher aktiver USB-Hub erforderlich. Dieser kann bei einem kabelgebundenen Ethernetanschluss und geschickter Wahl der Kamera vermieden werden.

Die oben genannte Hardware ist für circa 90 Euro erhältlich, wobei noch Einsparpotentiale bestehen, auf die im Verlauf der Arbeit eingegangen werden wird.

3.3 Software

Das System läuft mit RaspBian [95], einem speziell für den RPi entwickelten Debian-Derivat. Die Sturzerkennung ist ein in Python [96] implementierter Daemon mit drei nebenläufigen Threads.

320 Aufgezeichnete Ereignisse werden in einer SQLite-Datenbank gespeichert [97]. Für die Spracherkennung wird CMU Sphinx [98] eingesetzt.

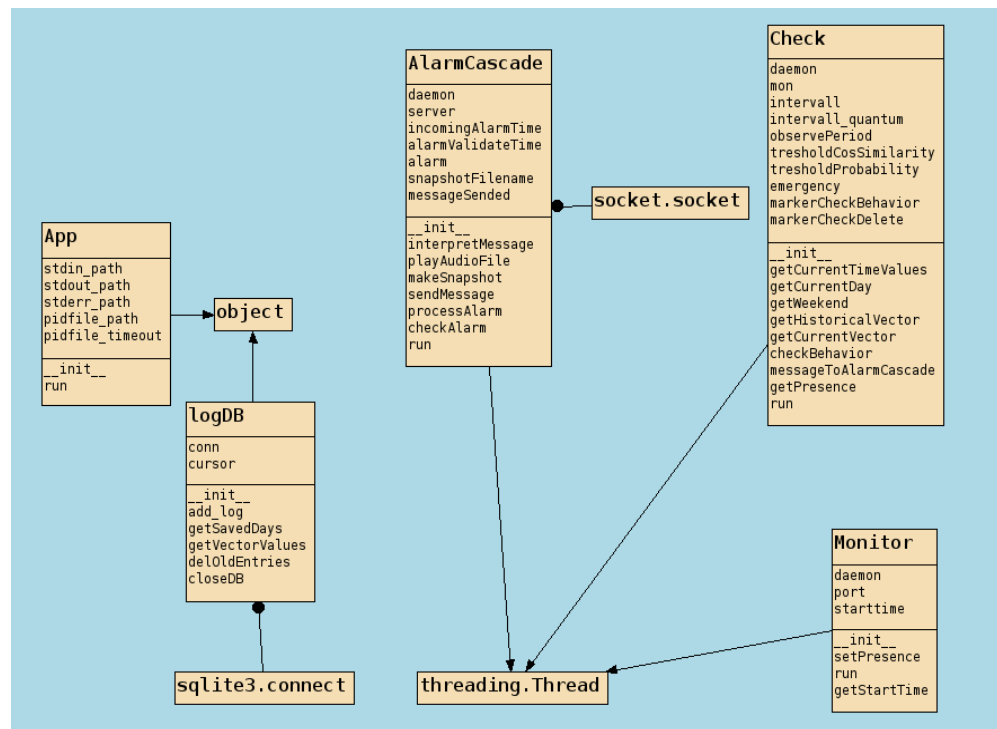


Abbildung 3.2: Klassendiagramm Sturzerkennung

4 Sturz und Aktivitätserkennung

4.1 Fallbeispiele

Fall A: Uroma Ursula, 74 Jahre alt, ist geistig absolut fit und noch gut zu Fuß. Sie kauft selbstständig ein, kocht für sich und geht einmal pro Woche zum Seniorentanz. Seit dem Tod ihres lieben Mannes vor drei Jahren lebt sie allein in der gemeinsamen Wohnung. Dienstags und donnerstags telefoniert sie mit ihrem Sohn Michael oder ihrer Enkelin Stefanie, die sie abwechselnd jeden Sonntag besuchen kommen. Gestern war wieder so ein Sonntag, an dem Ursula von Stefanie und Urenkel, dem vierjährigen Finn, besucht wurde. Es war ein bewegter Nachmittag und Ursula ging früh schlafen. Wie jede Nacht plagt sie um 3:00 Uhr ihre Blase. Sie hat den Weg zur Toilette schon hunderte Male zurück gelegt und findet ihn mit geschlossenen Augen. Doch heute zieht es ihr plötzlich die Beine weg, denn sie findet auch Finns überaus robustes Spielzeugauto. Später kommt sie mit starken Schmerzen in der Hüfte zu sich und stellt fest, dass sie in dieser Lage unmöglich ihr Telefon auf dem Schrank erreichen kann.

Fall B: Der 83jährige Wilhelm ist ein rüstiger Rentner, überzeugter Single und leidenschaftlicher Gärtner. Jeden Morgen schwingt er sich um 7:30 Uhr aus dem Bett und startet mit einer heißen Dusche in den Tag, um nach dem Frühstück in den Kiezzgarten zu gehen und seine Radieschenbeete von Unkraut und Gewürm zu befreien. Anschließend wird er sich mit seinen Kumpels an Pascha Haschas Imbiss zum Mittagessen treffen. Heute ist der erste Wasserstrahl besonders kalt. Wilhelm macht einen Hüpfer in der Badewanne, rutscht aus und registriert noch, wie er mit dem Kopf auf den Fliesen aufschlägt, bevor ihn wohltuende Schwärze umgibt.

4.2 Idee

Innerhalb eines Tages verbrauchen wir häufig Wasser, z.B. zum Spülen der Toilette, Händewaschen oder für die Nahrungszubereitung. In unserem zivilisierten Staat verfügt fast jede Wohnung über einen eigenen Wasseranschluss, von dem aus das Wasser an verschiedene Stellen in der Wohnung oder im Haus verteilt wird.

Die auf dem Wasserverbrauch basierende Sturz- und Aktivitätserkennung geht von der Annahme aus, dass Senioren einen geregelten Tagesablauf mit vielen sich wiederholenden Tätigkeiten haben und der Wasserverbrauch direkt hinter dem Wasseranschluss gemessen wird, so dass sich ohne großen Aufwand alle Verbrauchsstellen beobachten lassen.

4.3 Algorithmus Aktivitätserkennung

355 Der verwendete Flusssensor wird direkt hinter dem in Haus oder Wohnung mündenden Wasseranschluss installiert und fungiert als State-Sensor (S), der nur die Zustände „Wasser fließt“ ($S = 1$) oder „Wasser fließt nicht“ ($S = 0$) kennt. Dieser Zustand wird einmal pro Sekunde abgefragt und ausgewertet. Fließt Wasser, werden die Startzeit und Dauer der Wasserentnahme festgehalten und als Ereignis-Tupel $e = (Startzeit, Dauer)$ in eine Datenbank geschrieben 4.1.

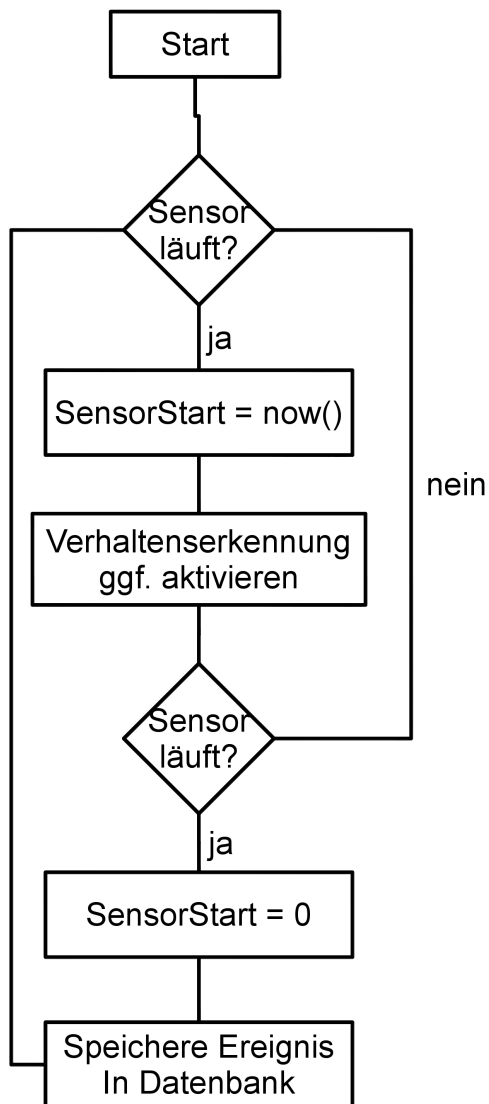


Abbildung 4.1: Flussdiagramm Monitoring

Bei der Auswertung werden Intervalle mit einer Länge von l Sekunden gebildet. Wenn innerhalb
 360 eines Intervalls einmal $S = 1$ auftritt, gilt dieser Wert für das gesamte Intervall. Auf diesem Weg
 werden auch viele kurze, rasch aufeinander folgende Ereignisse zusammengefasst. Mehrere auf-
 einander folgende Intervalle bilden einen Verhaltensvektor v , der aus mindestens drei Intervallen
 bestehen muss. v betrachtet die zurückliegenden $n * l$ Sekunden. Die Anzahl der Intervalle (n)
 ist prinzipiell frei wählbar, aber der Zeitraum sollte nicht zu groß gewählt werden. Der Faktor
 365 $n * l$ bildet auch eine Toleranz. Diese wird berücksichtigt, wenn das Verhalten der Vergangenheit
 mit dem aktuellen Verhalten abgeglichen wird, denn es ist davon auszugehen, dass auch in einem
 regelmäßigen Verhalten kleine Abweichungen auftreten können.

Neben dem in der Datenbank abgefragten Verhalten für die letzten $n * l$ Sekunden wird auch
 geprüft, ob gerade Wasser fließt. Die Daten werden erst in der Datenbank geschrieben, wenn der
 370 Wasserfluss beendet wurde, weshalb zu prüfen ist, ob und gegebenenfalls wie lange der Sensor
 bereits eine Aktivität feststellt.

Beispiel: Wenn für das Intervall 300 Sekunden angegeben wurden und der Verhaltensvektor
 aus drei Intervallen besteht, wird bei einem möglichen abweichenden Verhalten zum Zeitpunkt
 t anhand der Aufzeichnungen geprüft, mit welcher Wahrscheinlichkeit das Verhalten auftreten
 375 kann. Bei der Datenabfrage wird jedoch im Zeitraum $t \pm (n * l)$ sek nach Sensoraktivitäten
 gesucht.

Ferner kann festgelegt werden, wie viele Tage (D) das Verhalten aufgezeichnet werden soll. Sinn-
 voll sind Werte zwischen zehn und 30 Tagen. Bei der Auswertung wird zwischen Wochentagen
 sowie Wochenenden und Feiertagen unterschieden. Eine Aufzeichnungszeit von zehn Tagen würde
 380 zehn Wochentage und fünf Wochenenden, also insgesamt 20 Tage, beinhalten.

4.4 Abweichendes Verhalten erkennen

Wenn ein Rentner innerhalb eines Beobachtungszeitraumes Wasser entnimmt, das Wasser aber
 nicht die ganze Zeit fließt, geht es ihm vermutlich gut. Kritisch sind die Fälle, in denen kein
 Wasser fließt oder in denen lange Wasser fließt (siehe Fallbeispiele A und B). Um kritische Fälle
 385 K zu erkennen, wird der Verhaltensvektor normiert und anschließend eine Fallunterscheidung
 durchgeführt.

$$\|v\| = \sqrt{v_1^2 + v_2^2 + \dots + v_n^2} = \sqrt{\sum_{i=1}^n v_i^2}$$

$$K = \begin{cases} 1 & \text{falls } \|v\| = 0 \\ 1 & \text{falls } \|v\| = \sqrt{n} \\ 0 & \text{sonst} \end{cases}$$

Bei $K = 1$ fragt die Sturz- und Aktivitätserkennung für jeden Wert im Verhaltensvektor v die
 Datenbank an, wie es zu diesem Zeitpunkt in der Vergangenheit aussah. Dabei werden die To-

leranz berücksichtigt und ob Ereignisse für Wochentage oder Wochenenden/Feiertage zu prüfen
390 sind.

Alle gefundenen Ereignisse im Zeitraum $t \pm (n * l)$ sek werden summiert und durch die Anzahl beobachteter Tage D geteilt. So wird die Laplace-Wahrscheinlichkeit $P(e_t)$ gebildet:

$$\begin{aligned} P(e_t) &= \frac{\text{Anzahl Ereignisse zum Zeitpunkt } t \pm (n * l) \text{ sek}}{\text{Anzahl der aufgezeichneten Tage}} \\ &= \frac{\sum_{i=1}^D e_{i_{t \pm (n * l)}}}{D} \end{aligned}$$

Haben wir es mit einem „idealen“ Rentner zu tun, der jeden Tag daheim ist und zur selben Zeit innerhalb des Toleranzzeitraumes Wasser verbraucht, beträgt die Wahrscheinlichkeit 100
395 Prozent ($P(e_t) = 1$). Da Rentner und ihr Leben meist nicht ideal sind, wird die Wahrscheinlichkeit in vielen Fällen geringer ausfallen. Darum wird ein Schwellwert u für „ziemlich sicheres Verhalten“ gesetzt, der auch berücksichtigt, dass mal verschlafen wird oder der geregelte Tagesablauf vereinzelt abweicht. Wird eine Wahrscheinlichkeit ermittelt, die unter diesem Schwellwert bleibt, werden alle betroffenen Ereignisse nicht berücksichtigt und die Wahrscheinlichkeit auf
400 ($P(e_t) = 0$) gesetzt. So wird auch verhindert, dass selten auftretende Ereignisse (z.B. Besuch geht auf Toilette, schwitzende Bauarbeiter bitten um ein Glas Wasser etc.) gewertet werden.

Die Wahrscheinlichkeitswerte werden in einen „historischen Verhaltensvektor“ h eingetragen, der aus demselben Vektorraum wie v kommt ($v, h \in \mathbb{R}^n$). v und h werden anschließend mittels Cosinusähnlichkeit $\cos(\varphi)$ verglichen, wobei φ der Winkel zwischen v und h ist:

$$\begin{aligned} \cos(\varphi) &= \frac{v \cdot h}{\sqrt{\|v\|} * \sqrt{\|h\|}} \\ &= \frac{\sum_{i=1}^n v_i * h_i}{\sqrt{\sum_{i=1}^n v_i^2} * \sqrt{\sum_{i=1}^n h_i^2}} \end{aligned}$$

405 $\cos(\varphi) = 1$ würde völlige Übereinstimmung bedeuten, bei $\cos(\varphi) = 0$ sind v und h zueinander orthogonal und ähneln sich kein bisschen. Um unübliches Verhalten zu erkennen, wird auch für die Cosinusähnlichkeit ein Schwellwert s in Abhängigkeit der Anzahl der betrachteten Intervalle (n) gesetzt. Für den Standardwert $n = 3$ wäre beispielsweise $s = 0,7$ ein guter Ausgangsschwellwert.

410 Je zu Beginn eines jeden Intervalls ($\text{timestamp} \bmod l \leq 25$) wird der letzte Verhaltensvektor ausgewertet und gegebenenfalls (bei $K = 1$) mit dem historischen Verhaltensvektor verglichen. Tritt mehrmals ($3n$) hintereinander ein $\cos(\varphi) \leq s$ auf, wird die Alarmkaskade angestoßen.

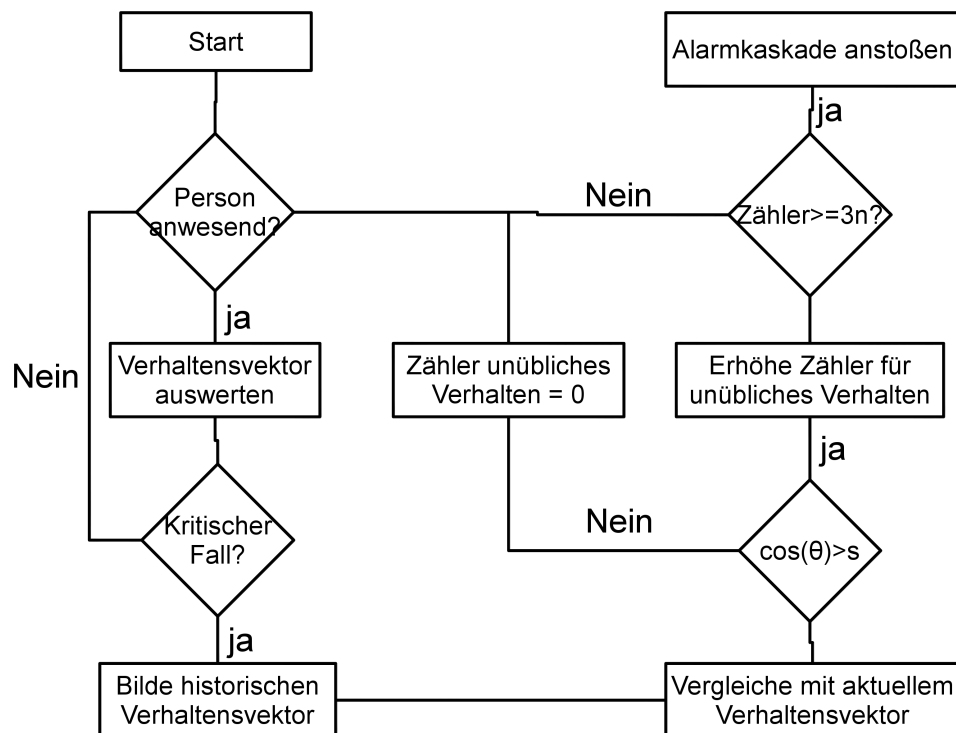


Abbildung 4.2: Flussdiagramm Sturzerkennung

4.5 Abwesenheit

Es ist möglich, die Aktivitätserkennung zu informieren, wenn der Senior das Haus oder die Wohnung verlässt, etwa um Urlaub zu machen, einen Abend bei Freunden oder ein Wochenende bei Angehörigen zu verbringen. In dem Fall werden die Verhaltenskontrolle deaktiviert und unbeabsichtigte Fehlalarme vermieden. Mit dem nächsten Wasserverbrauch wird das System automatisch wieder aktiviert.

5 Alarmkaskade

420 Die Alarmkaskade ist im Alarmfall dafür verantwortlich, Angehörige oder Pflegepersonal über einen vermutlichen Sturz zu informieren. Die Alarmkaskade kommuniziert mit der Aktivitätserkennung über einen Unix-Socket. Alle dort empfangenen Nachrichten („ALARM“, „UNEXPECTED BEHAVIOR“, „FINE“) werden interpretiert.

425 Stellt die Aktivitätserkennung ein abweichendes Verhalten fest, sendet sie die Nachricht „UNEXPECTED BEHAVIOR“ an die Alarmkaskade. Diese spielt eine Audiodatei ab, in der der Senior aufgefordert wird, sein Wohlergehen zu bestätigen (Nachricht „FINE“). Dafür hat er per default zwei Minuten Zeit.

430 Fehlalarme können relativ häufig auftreten, je nachdem welche Werte für Intervalle, Verhaltensvektoren oder Schwellwerte gesetzt wurden oder wenn sich das Verhalten ändert, z.B. wenn der Sturzgefährdete morgens eine halbe Stunde länger schlafen möchte. Geht es dem Senior gut, kann er den Alarm durch eine einfache Aktivität abbrechen. Ein Fehlalarm ist für den Senior nicht mehr als eine lästige Störung, die deutlich weniger kostet als ein (von Angehörigen oder Pflegedienst unbemerkter) Sturz.

435 Bestätigt der Rentner innerhalb dieser Zeitspanne sein Wohlergehen nicht oder empfängt die Alarmkaskade die Nachricht „ALARM“, wird ein Alarm ausgelöst. Dazu macht die Webcam ein Foto, das anschließend zusammen mit der Aufforderung, sich um den Rentner zu kümmern, per E-Mail oder MMS an eine Empfängerliste versendet wird 5.1.

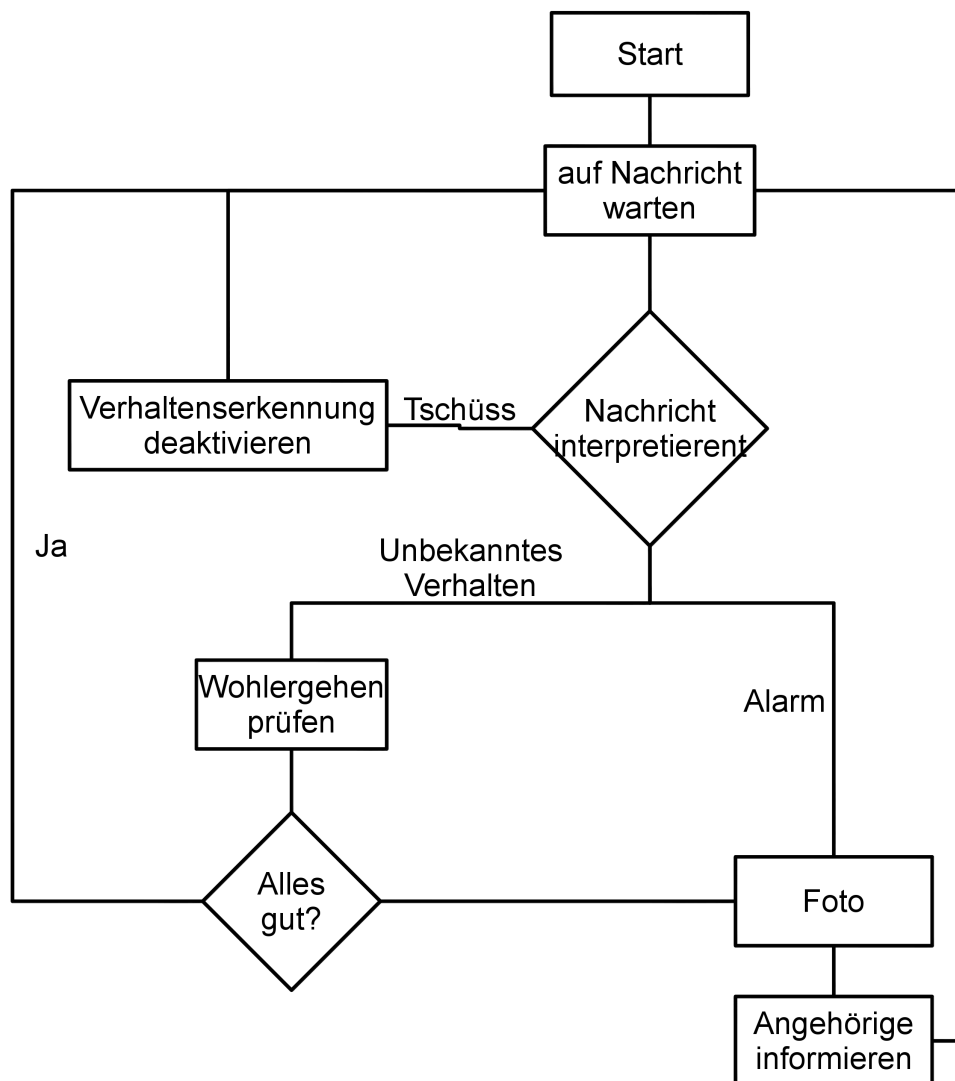


Abbildung 5.1: Flussdiagramm Alarmkaskade

6 Test

Die Sturzerkennung wurde circa einen Monat lang in einem Haushalt getestet. Dabei zeigte sich, dass das System zuverlässig funktionierte. Es stürzte kein einziges Mal ab. Die Probleme lagen an anderer Stelle begründet. Grafik 6.1 zeigt, wann Wasser verbraucht wurde.




Abbildung 6.1: Wasserverbrauch während des aufgezeichneten Zeitraums

Aus den Grafiken 6.2 und 6.3 ist ersichtlich, dass die Voraussetzung der regelmäßigen Wasserentnahme bei der Testperson nicht gegeben war. Der Schwellwert u für „ziemlich sicheres Verhalten“




Abbildung 6.2: Wahrscheinlichkeit der Wasserentnahme an Wochentagen




Abbildung 6.3: Wahrscheinlichkeit der Wasserentnahme an Wochenenden

wird nur selten überschritten. Hier müssten entweder die Schwellwerte angepasst oder die Toleranz erhöht werden. Würde die Versuchsperson verunglücken, würden im schlimmsten Fall erst nach circa 24 Stunden Angehörige informiert werden, beispielsweise wenn der Sturz kurz nach Mitternacht erfolgt. Am Wochenende würde dieser Zeitraum mit der obigen Konfiguration mit circa 14 Stunden ebenfalls noch sehr lang sein.

Das Datenaufkommen war sehr gering. Während des vierwöchigen Tests wuchs die SQLite-Datenbank auf gerade einmal 6 KB an und enthielt nur wenige hundert Werte. Hier werden täglich die ältesten Werte gelöscht, sobald die Anzahl der aufzuzeichnenden Tage (D) überschritten wird.

6.1 Probleme in der Praxis

Während des Testlaufs traten mehrere Probleme auf. Ein Flusssensor leckte so stark, dass er nicht in einer häuslichen Umgebung verbaut werden konnte. In vielen Haushalten würde sich der Wasserverbrauch auch ohne Flusssensoren feststellen lassen, z.B. indem eine ausgeschaltete optische Maus über der Wasseruhr positioniert wird, die die Bewegungen des Rollenzählwerks registriert. Allerdings lauern auch hier Tücken. Es gibt beispielsweise Wasserzähler mit Funkmodulen, die ein spezielles Linsen- und Beleuchtungssystem erfordern, um Zählerbewegungen feststellen zu können. Wird eine Maus anstelle des Flusssensors verwendet, würden sich die Kosten für die nötige Hardware um circa 25 Euro verringern, da sich in dem Fall auch das Mikrokontrollerboard einsparen ließe.

Weitere Überraschungen lagen in der Empfindlichkeit des Sensors, der auch ein Tropfen des Wasserhahns oder leichte Erschütterungen als Wasserentnahme interpretiert. Innerhalb der ersten zwei Tage des Feldversuchs fanden sich in der Datenbank mehr als 2.000 Datensätze, für die es keine Entsprechungen in der Realität gab.

Die geplante Schnittstelle mittels der Spracherkennung erwies sich als hakelig und wurde nicht innerhalb des Projektzeitraums umgesetzt. Die Spracherkennung erfordert ein aus Wörterbuch und Grammatik bestehendes Sprachmodell sowie ein akustisches Modell. Letzteres enthält die in Phoneme und Piphone zerlegten Wörter des Wörterbuches. Für die Aktivitätserkennung wären drei Kommandos (z.B. „Alarm“, „alles in Ordnung“ und „Tschüss“) sowie ein Trigger nötig. Der Trigger sollte ein Wort sein, das im gewöhnlichen Gespräch nie oder nur sehr selten vorkommt. Er wird jedem Kommando vorangestellt, um falsch erkannte Kommandos zu vermeiden. Um das Akustik-Modell der Spracherkennung auf die Stimme eines Sprechers zu trainieren, ist ungefähr eine Stunde Training erforderlich.

7 Fazit und Ausblick

Es ist möglich, eine preiswerte, auf dem Wasserverbrauch basierende Aktivitätserkennung zu entwickeln, die nur ein Minimum an Konfiguration erfordert, das Verhalten selbstständig erlernt und einen hohen Schutz der Privatsphäre gewährleistet. Das System würde nicht nur Stürze feststellen, sondern auch andere Unglücksfälle, etwa wenn die überwachte Person auf Schaukelstuhl, Sofa oder im Bett entschläft.

Allerdings müssen verschiedene Rahmenbedingungen erfüllt sein, damit diese zuverlässig funktioniert. So ist das System nur für Personen geeignet, die einen geregelten, sich wiederholenden Tagesablauf mit nur geringen Abweichungen haben. Ist die Regelmäßigkeit nicht gegeben, funktioniert die Aktivitätserkennung nicht oder nur eingeschränkt. Ferner ist sicherzustellen, dass nur der Wasseranschluss der Wohneinheit des alleinlebenden Seniors überwacht wird. Um die Alarmkaskade anzustoßen, ist ein Internet-Anschluss nötig, der gerade in der Zielgruppe 65+ noch nicht überall zu finden ist.

Es ist nicht möglich, mit der hier vorgestellten Sturz- und Aktivitätserkennung Stürze in Echtzeit zu erfassen und das sogenannte Long Lie zu verhindern. Stürzt der Überwachte kurz vor der üblichen Wasserentnahme und verliert dabei das Bewusstsein, vergeht ca. eine Zeit von 2nl, ehe die Alarmkaskade angestoßen wird. Im schlimmsten anzunehmenden Fall muss die betroffene Person die Längste Zeit zwischen zwei Wasserentnahmen am Boden verbringen.

Der Ethernet-Anschluss des RPi sollte einem WLAN-Stick vorgezogen werden. In Umgebungen mit WPA-PSK- oder WPA2-gesicherten drahtlosen Netzen funktionierte das System mit WLAN tadellos. In Netzen, die durch WPA-EAP geschützt wurden, verlor es nach einiger Zeit die Internetverbindung und konnte sie nicht automatisch wieder herstellen. Hier ist gegebenenfalls eine Sicherung zu installieren, die in kurzen Zeitabständen die Internetverbindung prüft und Nutzer bei Problemen informiert.

Die zukünftige Arbeit wird sich darauf konzentrieren, eine Spracherkennungslösung als Nutzerschnittstelle bereitzustellen und Erfahrungen mit verschiedenen Schwellwerten auszuwerten, so dass Anwendern allgemeingültige Empfehlungen gegeben werden können. Um hier einen Erfahrungsschatz aufzubauen, wird die Software unter einer Open-Source-Lizenz veröffentlicht. Um auch Aktivitäten zu erkennen, die mit mehrtägigen Abstand regelmäßig auftreten, sind ebenfalls weitere Untersuchungen nötig.

Der Flusssensor liefert sehr differenzierte Werte, mittels derer nicht nur festgestellt werden kann, ob Wasser fließt, sondern auch, wieviel Wasser fließt. Hier wären Fingerabdrücke des Verbrauchs denkbar, mit deren Hilfe Rückschlüsse auf die ausgeübte Tätigkeit möglich wären, beispielsweise Toilettenspülung, Abwaschen oder Duschen. Diese könnten später mit in die Verhaltensanalyse einbezogen werden.

Abkürzungsverzeichnis

AAL	Ambient Assisted Living
GPIO	General Purpose Input/Output
RPi	Raspberry Pi
SVM	Support Vector Machine

Glossar

Ambient Assisted Living

515 Unter „Ambient Assisted Living“ werden Konzepte, Produkte und Dienstleistungen verstanden, die neue Technologien und soziales Umfeld mit dem Ziel verbinden und verbessern, die Lebensqualität für Menschen in allen Lebensabschnitten, vor allem im Alter, zu erhöhen.

Beamforming

ist ein Verfahren zur Positionsbestimmung von Schallquellen.

General Purpose Input/Output

520 ist ein generischer Pin auf einem Chip, dessen Verhalten zur Laufzeit von Nutzer kontrolliert werden kann.

Gyroskop

ist ein Gerät zum Messen von Winkeln und Winkelgeschwindigkeiten, mit dem sich Positionsänderungen erfassen lassen.

525 **Long Lie**

bedeutet, dass eine Person eine Stunde und länger hilflos am Boden liegt und nicht fähig ist, selbstständig aufzustehen

Support Vector Machine

SVMs können in der Mustererkennung als Klassifikatoren eingesetzt werden.

530 Literaturverzeichnis

- [1] Statistisches Bundesamt. 12. koordinierte Bevölkerungsvorausberechnung. Webseite, 2009. <https://www.destatis.de/DE/Publikationen/Thematisch/Bevoelkerung/VorausberechnungBevoelkerung/BevoelkerungDeutschland2060Presse.html> [zuletzt besucht am 28.03.2013].
- 535 [2] Statistisches Bundesamt. Alleinlebende in Deutschland, Ergebnisse des Mikrozensus 2011. Webseite, 2012. <https://www.destatis.de/DE/Publikationen/Thematisch/Bevoelkerung/HaushalteMikrozensus/AlleinlebendeInDeutschlandPresse.html> [zuletzt besucht am 28.03.2013].
- [3] Tahir Masud and Robert Morris. Epidemiology of falls. *Age Ageing*, 30(4):3–7, November 540 2001.
- [4] Sachiyo Yoshida. A global report on falls prevention: Epidemiology of falls. Webseite, 2007. <http://www.who.int/ageing/projects/1.Epidemiologyoffallsinolderage.pdf> [zuletzt besucht am 28.03.2013].
- 545 [5] Parachute. The economic burden of injury in canada. Website, 2009. <https://www.destatis.de/DE/Publikationen/Thematisch/Bevoelkerung/HaushalteMikrozensus/AlleinlebendeInDeutschlandPresse.html> [zuletzt besucht am 03.04.2013].
- [6] M. E. Tinetti, J. Doucette, E. Claus, and R. Marottoli. Risk factors for serious injury during falls by older persons in the community. *Journal of the American Geriatrics Society*, 550 43(11):1214–1221, November 1995.
- [7] Douglas P. Kiel. Falls. *Rhode Island Medical Journal*, 74(2):75–79, February 1991.
- [8] S. Sadigh, A. Reimers, R. Andersson, and L. Laflamme. Falls and fall-related injuries among the elderly: a survey of residential-care facilities in a swedish municipality. *The Journal of Community Health*, 2(2):129–140, April 2004.
- 555 [9] M. Gostynsk. Prevalence, circumstances and consequences of falls in institutionalized elderly; a pilot study. *Sozial- und Präventivmedizin*, 36(6):341–345, 1991.
- [10] R. Jan Gurley, Nancy Lum, Merle Sande, Bernard Lo, and Mitchell H. Katz. Persons found in their homes helpless or dead. *The New England Journal of Medicine*, 334(26):1710–1716, June 1996.

- 560 [11] D. Wild, U. S. Nayak, and B. Isaacs. How dangerous are falls in old people at home? *British Medical Journal*, 282(6260):266–268, January 1981.
- [12] J. Magaziner, E. M. Simonsick, T. M. Kashner, J. R. Hebel, and J. E. Kenzora. Survival experience of aged hip fracture patients. *American Journal of Public Health*, 79(3):274–278, March 1989.
- 565 [13] M. Weatherall. One year follow up of patients with fracture of the proximal femur. *The New Zealand Medical Journal*, 107(983):308–309, August 1994.
- [14] Y. Folman, R. Gepstein, A. Assaraf, and S. Liberty. Functional recovery after operative treatment of femoral neck fractures in an institutionalized elderly population. *Archives of Physical Medicine and Rehabilitation*, 75(4):454–456, April 1994.
- 570 [15] Charles J. Lord and David P. Colin. Falls in the elderly: Detection and assessment. In *Proceedings of the Annual International Conference of the IEEE*, volume 13, pages 1938–1939, November 1991.
- [16] N. Noury, A. Fleury, P. Rumeau, A.K. Bourke, G. ÓLaighin, V. Rialle, and J.E. Lundy. Fall detection - principles and methods. In *29th Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, pages 1663–1666. Univ. Joseph Fourier, Grenoble, August 2007.
- 575 [17] Jan Goebel and Markus M. Grabka. Zur Entwicklung der Altersarmut in Deutschland. *Wochenbericht des DIW Berlin*, 25:3–16, 2011.
- [18] Angelika Hellemann. Die neue Renten-Schock-Tabelle. Website, September 2012. <http://www.bild.de/geld/wirtschaft/wirtschaft/altersarmut-bei-weniger-als-2500-euro-25989322.bild.html> [zuletzt besucht am 03.04.2013].
- 580 [19] Bertelsmann Stiftung. Pflegereport 2030. Website, November 2012. http://www.bertelsmann-stiftung.de/cps/rde/xchg/bst/hs.xsl/nachrichten_114244.htm [zuletzt besucht am 04.04.2013].
- 585 [20] Statistisches Bundesamt. Pflegestatistik 2011. Webseite, 2013. https://www.destatis.de/DE/PresseService/Presse/Pressemitteilungen/2013/01/PD13_024_224.html [zuletzt besucht am 04.04.2013].
- [21] J.Y. Hwang, J.M. Kang, Y.W. Jang, and H. C. Kim. Development of novel algorithm and real-time monitoring ambulatory system using bluetooth module for fall detection in the elderly. In *26th Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, pages 2204–2207, September 2004.
- 590 [22] Jay Chen, Karris Kwong, Dennis Chang, Jerry Luk, and Ruzena Bajcsy. Wearable sensors for reliable fall detection. In *27th Annual International Conference of the Engineering in Medicine and Biology Society*, pages 3551–3554, Januar 2006.
- 595

- [23] Maarit Kangas, Antti Konttila, Ilkka Winblad, and Timo Jämsä. Determination of simple thresholds for accelerometry-based parameters for fall detection. In *29th Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, pages 1367–1370, 2007.
- 600 [24] Soundararajan Srinivasan, Jun Han, Dhananjay Lal, and Aca Gacic. Towards automatic detection of falls using wireless sensors. In *29th Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, pages 1379–1382. Robert Bosch LLC, Pittsburgh, August 2007.
- 605 [25] Alan K. Bourke, Pepijn W.J. van de Ven, Amy E. Chaya, Gearóid M. ÓLaighin, and John Nelson. The design and development of a long-term fall detection system incorporated into a custom vest for the elderly. In *30th Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, pages 2836–2839. Wireless Access Research Centre, Department of Electronic and Computer Engineering, University of Limerick, August 2008.
- 610 [26] Alan K. Bourke, Pepijn W.J. van de Ven, Amy E. Chaya, Gearóid M. ÓLaighin, and John Nelson. Testing of a long-term fall detection system incorporated into a custom vest for the elderly. In *30th Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, pages 2844–2847. Wireless Access Research Centre, Department of Electronic and Computer Engineering, University of Limerick, Ireland, August 2008.
- 615 [27] Manuel Prado-Velasco, María Gloria del Río-Cidoncha, and Rafael Ortiz-Marín. The inescapable smart impact detection system (isis): An ubiquitous and personalized fall detector based on a distributed “divide and conquer strategy”. In *30th Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, pages 3332–3335. Research and Development Department, SHS Consultores, Spain, August 2008.
- 620 [28] Khalil Niazmand, Claudius Jehle, Lorenzo T. D’Angelo, and Tim C. Lueth. A new washable low-cost garment for everyday fall detection. In *Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, pages 6377–6380. Dept. of Micro Technol. & Med. Device Technol., Tech. Univ. Muenchen, Garching, Germany, August 2010.
- 625 [29] S. Y. Sim, H. S. Jeon, G. S. Chung, S. K. Kim, S. J. Kwon, W. K. Lee, and K. S. Park. Fall detection algorithm for the elderly using acceleration sensors on the shoes. In *Annual International Conference of the IEEE Engineering in Medicine and Biology Society, EMBC*, pages 4935–4938. Interdiscipl. Program of Bioeng., Seoul Nat. Univ., Seoul, South Korea, September 2011.
- 630 [30] Huang Cheng, Haiyong Luo, and Fang Zhao. A fall detection algorithm based on pattern recognition and human posture analysis. In *IET International Conference on Communication Technology and Application (ICCTA 2011)*, pages 853–857. Software School, Beijing University of Posts and Telecommunications, 100876, China, October 2011.
- 635 [31] Shuai Huang, Yujiu Yang, and Wenhuan Liu. An enhanced fall detection approach based on cost sensitivity analysis. In *First ACIS International Symposium on Software and Network Engineering (SSNE)*, pages 81–85. Grad. Sch. at Shenzhen, Tsinghua Univ., Shenzhen, China, December 2011.

- [32] Mitchell Yuwono, Bruce D. Moulton, Steven W. Su, Branko G. Celler, and Hung T. Nguyen. Unsupervised machine-learning method for improving the performance of ambulatory fall-detection systems. *Biomedical Engineering Online*, 11:1–11, 2012.
- 640 [33] Toshiyo Tamura, Takumi Yoshimura, Masaki Sekine, Mitsuo Uchida, and Osamu Tanaka. A wearable airbag to prevent fall injuries. *IEEE Transactions on Information Technology in Biomedicine*, 13(6):910 – 914, November 2009.
- [34] M.N. Nyan, Francis E.H. Tay, and E. Murugasu. A wearable system for pre-impact fall detection. *Journal of Biomechanics*, 41(16):3475–3481, December 2008.
- 645 [35] Raymond Y. W. Lee and Alison J. Carlisle. Detection of falls using accelerometers and mobile phone technology. *Age and Ageing*, 40(6):690–696, November 2011.
- [36] Fabio Bagala, Clemens Becker, Angelo Cappello, Lorenzo Chiari, Kamiar Aminian, Jeffrey M. Hausdorff, Wiebren Zijlstra, and Jochen Klenk. Evaluation of accelerometer-based fall detection algorithms on real-world falls. *PLoS One*, 7(5):e37062, 2012.
- 650 [37] Frank Sposaro and Gary Tyson. ifall: An android application for fall monitoring and response. In *Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, pages 6119–6122. Florida State Univ., Tallahassee, FL, USA, September 2009.
- [38] Stefano Abbate, Marco Avvenuti, Guglielmo Cola, Paolo Corsini, Janet Light, and Alessio Vecchio. Recognition of false alarms in fall detection systems. In *IEEE Consumer Communications and Networking Conference (CCNC)*, pages 23–28. IMT Inst. for Adv. Studies, Lucca, Italy, January 2011.
- 655 [39] Miguel Angel Estudillo-Valderrama, Laura M. Roa, Javier Reina-Tosina, and David Naranjo-Hernandez. Design and implementation of a distributed fall detection system—personal server. *IEEE Transactions on Information Technology in Biomedicine*, 13(6):874–881, November 2009.
- 660 [40] Ronald Nocua, Norbert Noury, Claudine Gehin, Andre Dittmar, and Eric McAdams. Evaluation of the autonomic nervous system for fall detection. In *Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, pages 3225–3228. Lab. TIMC-IMAG, Team AFIRM, La Tronche, France, September 2009.
- 665 [41] Thuy-Trang Nguyen, Myeong-Chan Cho, and Tae-Soo Lee. Automatic fall detection using wearable biomedical signal measurement terminal. In *Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, pages 5203–5206. Dept. of Biomed. Eng., Chungbuk Nat. Univ., Cheongju, South Korea, September 2009.
- [42] Federico Bianchi, Stephen J. Redmond, Michael R. Narayanan, Sergio Cerutti, Branko G. Celler, and Nigel H. Lovell. Falls event detection using triaxial accelerometry and barometric pressure measurement. In *Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, pages 6111–6114. Dept. of Biomed. Eng., Politec. di Milano, Milan, Italy, September 2009.
- 670

- [43] Federico Bianchi, Stephen J. Redmond, Michael R. Narayanan, Sergio Cerutti, and Nigel H. Lovell. Barometric pressure and triaxial accelerometry-based falls event detection. *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, 18(6):619–627, December 2010.
- [44] Marie Tolkiehn, Louis Atallah, Benny Lo, and Guang-Zhong Yang. Direction sensitive fall detection using a triaxial accelerometer and a barometric pressure sensor. In *Annual International Conference of the IEEE Engineering in Medicine and Biology Society, EMBC*, pages 369–372. The Hamlyn Centre, Imperial College London, September 2011.
- [45] Hassan Ghasemzadeh, Vitali Loseu, and Roozbeh Jafari. Structural action recognition in body sensor networks: Distributed classification based on string matching. *IEEE Transactions on Information Technology in Biomedicine*, 14(2):425 – 435, March 2010.
- [46] Hristijan Gjoreski, Mitja Lustrek, and Matjaz Gams. Accelerometer placement for posture recognition and fall detection. In *7th International Conference on Intelligent Environments (IE)*, pages 47–54. Dept. of Intell. Syst., Jozef Stefan Inst., Ljubljana, Slovenia, July 2011.
- [47] Sung-Yen Chang, Chin-Feng Lai, Han-Chieh Josh Chao, Jong Hyuk Park, and Yueh-Min Huang. An environmental-adaptive fall detection system on mobile device. *Journal of medical systems*, 35(5):1299–1312, October 2011.
- [48] J. Klenk, C. Becker, F. Lieken, S. Nicolai, W. Maetzler, W. Alt, W. Zijlstra, J.M. Hausdorff, R.C. van Lummel, L. Chiari, and U. Lindemann. Comparison of acceleration signals of simulated and real-world backward falls. *Medical Engineering and Physics*, 33(3):386–373, April 2011.
- [49] Hammadi Nait-Charif and Stephen J. McKenna. Activity summarisation and fall detection in a supportive home environment. In *Proceedings of the 17th International Conference on Pattern Recognition*, volume 4, pages 323–326. Division of Applied Computing, University of Dundee, Dundee DD1 4HN, Scotland, August 2004.
- [50] Homa Foroughi, Baharak Shakeri Aski, and Hamidreza Pourreza. Intelligent video surveillance for monitoring fall detection of elderly in home environments. In *11th International Conference on Computer and Information Technology*, pages 219–224, December 2008.
- [51] Tim Liao and Chung-Lin Huang. Slip and fall events detection by analyzing the integrated spatiotemporal energy map. In *20th International Conference on Pattern Recognition (ICPR)*, pages 1718–1721. Electr. Eng. Dept., Nat. Tsing-Hua Univ., Hsinchu, Taiwan, August 2010.
- [52] Muhammad Shoaib, Ralf Dragon, and Jörn Ostermann. View-invariant fall detection for elderly in real home environment. In *Fourth Pacific-Rim Symposium on Image and Video Technology (PSIVT)*, pages 52–57. Inst. fur Informationsverarbeitung, Leibniz Univ., Hannover, Germany, November 2010.
- [53] Miao Yu, Adel Rhuma, Syed Mohsen Naqvi, Liang Wang, and Jonathon Chambers. A posture recognition-based fall detection system for monitoring an elderly person in a

- smart home environment. *IEEE Transactions on Information Technology in Biomedicine*, 16(6):1274–1286, November 2012.
- [54] Homa Foroughi, Hadi Sadoghi Yazdi, Hamidreza Pourreza, and Malihe Javidi. An eigenspace-based approach for human fall detection using integrated time motion image and multi-class support vector machine. In *4th International Conference on Intelligent Computer Communication and Processing*, pages 83–90. Department of Computer Engineering, Ferdowsi University of Mashhad, Mashhad, Iran, August 2008.
- [55] Homa Foroughi, Aabed Naseri, Alireza Saberi, and Hadi Sadoghi Yazdi. An eigenspace-based approach for human fall detection using integrated time motion image and neural network. In *9th International Conference on Signal Processing, 2008*, pages 1499–1503, October 2008.
- [56] Shaou-Gang Miaou, Pei-Hsu Sung, and Chia-Yuan Huang. A customized human fall detection system using omni-camera images and personal information. In *1st Transdisciplinary Conference on Distributed Diagnosis and Home Healthcare, 2006. D2H2*, pages 39–42, April 2006.
- [57] Bart Jansen and Rudi Deklerck. Context aware inactivity recognition for visual fall detection. In *Pervasive Health Conference and Workshops, 2006*. Electronics and Informatics Department Vrije Universiteit Brussel, December 2006.
- [58] Qingcong Lv. A poselet-based approach for fall detection. In *International Symposium on IT in Medicine and Education (ITME)*, pages 209–212. Dept. of Cognitive Sci., Xiamen Univ., Xiamen, China, December 2011.
- [59] Derek Anderson, James M. Keller, Marjorie Skubic, Xi Chen, and Zhihai He. Recognizing falls from silhouettes. In *28th Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, pages 6388–6391. Department of Electrical and Computer Engineering, University of Missouri, Columbia, September 2006.
- [60] Arie Hans Nasution and Sabu Emmanuel. Intelligent video surveillance for monitoring elderly in home environments. In *9th Workshop on Multimedia Signal Processing*, pages 203–206. School of Computer Engineering, Nanyang Technological University, Singapore, October 2007.
- [61] G. Diraco, A. Leone, and P. Siciliano. An active vision system for fall detection and posture recognition in elderly healthcare. In *Conference & Exhibition Design, Automation & Test in Europe*, pages 1536–1541. CNR-IMM, Lecce, Italy, March 2010.
- [62] Alessandro Leone, Giovanni Diraco, and Pietro Siciliano. Detecting falls with 3d range camera in ambient assisted living applications: a preliminary study. *Medical Engineering and Physics*, 33(6):770–781, July 2011.
- [63] Young-Sook Lee and Wan-Young Chung. Visual sensor based abnormal event detection with moving shadow removal in home healthcare applications. *Sensors*, 12(1):573–584, 2012.

- [64] Edouard Auvinet, Lionel Reveret, Alain St-Arnaud, Jacqueline Rousseau, and Jean Meunier. Fall detection using multiple cameras. In *30th Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, pages 2554–2557. Institut de genie biomedical, University of Montreal, Quebec, Canada, August 2008.
- [65] Edouard Auvinet, Franck Multon, Alain Saint-Arnaud, Jacqueline Rousseau, and Jean Meunier. Fall detection with multiple cameras: An occlusion-resistant method based on 3-d silhouette vertical distribution. *IEEE Transactions on Information Technology in Biomedicine*, 15(2):290–300, March 2011.
- [66] Derek Anderson, Robert H. Luke, James M. Keller, Marjorie Skubic, Marilyn Rantz, and Myra Aud. Linguistic summarization of video for fall detection using voxel person and fuzzy logic. *Computer vision and image understanding*, 113(1):80–89, January 2009.
- [67] Alan K. Bourke, Karol J. O’Donovan, John Nelson, and Gearóid M. O’Laighin. Fall-detection through vertical velocity thresholding using a tri-axial accelerometer characterized using an optical motion-capture system. In *30th Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, pages 2832–2835. Wireless Access Research Centre, Department of Electronic and Computer Engineering, University of Limerick, Ireland, August 2008.
- [68] Miao Yu, Adel Rhuma, Syed Mohsen Naqvi, and Jonathon Chambers. Fall detection for the elderly in a smart room by using an enhanced one class support vector machine. In *Electron. & Electr. Eng. Dept., Loughborough Univ., Leicester, UK*, pages 1–6. Electron. & Electr. Eng. Dept., Loughborough Univ., Leicester, UK, July 2011.
- [69] M. Yu, S.M. Naqvi, A. Rhuma, and J. Chambers. One class boundary method classifiers for application in a video-based fall detection system. *Computer Vision, IET*, 6(2):90 – 100, March 2012.
- [70] Anh Tuan Nghiem, Edouard Auvinet, and Jean Meunier. Head detection using kinect camera and its application to fall detection. In *11th International Conference on Information Science, Signal Processing and their Applications (ISSPA)*, pages 164–169. Dept. of Comput. Sci. & Oper. Res., Univ. of Montreal, Montreal, QC, Canada, July 2012.
- [71] M.N. Nyan, Francis E.H. Tay, and Matthew Z.E. Maha. Application of motion analysis system in pre-impact fall detection. *Journal of Biomechanics*, 41(10):2297–2304, July 2008.
- [72] Bin Huang, Guohui Tian, and Hao Wu. A method for fast fall detection based on intelligent space. In *IEEE International Conference on Automation and Logistics*, pages 2260–2265. School of Control Science and engineering, Shandong University, September 2008.
- [73] Ahmed Nabil Belbachir, Stephan Schraml, and Aneta Nowakowska. Event-driven stereo vision for fall detection. In *IEEE Computer Society Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, pages 78–83. New Sensor Technol., Safety & Security Dept., AIT Austrian Inst. of Technol., Vienna, Austria, June 2011.
- [74] A.N. Belbachir, M. Litzenberger, S. Schraml, M. Hofstätter, D. Bauer, P. Schön, M. Humenberger, C. Sulzbachner, T. Lunden, and M. Merne. Care: A dynamic stereo vision

- sensor system for fall detection. In *IEEE International Symposium on Circuits and Systems (ISCAS)*, pages 731–734. AIT Austrian Inst. of Technol., Vienna, Austria, May 2012.
- 790 [75] Martin Humenberger, Stephan Schraml, Christoph Sulzbachner, Ahmed Nabil Belbachir, Agoston Srp, and Ferenc Vajda. Embedded fall detection with a neural network and bio-inspired stereo vision. In *IEEE Computer Society Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, pages 60–67. AIT Austrian Inst. of Technol., Vienna, Austria, June 2012.
- 795 [76] Mihail Popescu, Yun Li, Marjorie Skubic, and Marilyn Rantz. An acoustic fall detector system that uses sound height information to reduce the false alarm rate. In *30th Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, pages 4628–4631. Health Management and Informatics Department, University of Missouri, Columbia, USA, October 2008.
- 800 [77] Mihail Popescu and Abhishek Mahnot. Acoustic fall detection using one-class classifiers. In *Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, pages 3505–3508. Health Manage. & Inf. Dept., Univ. of Missouri, Columbia, MO, USA, September 2009.
- [78] Dima Litvak, Israel Gannot, and Yaniv Zigel. Detection of falls at home using floor vibrations and sound. In *25th Convention of Electrical and Electronics Engineers in Israel*, pages 514–518, December 2008.
- 805 [79] Yun Li, Zhiling Zeng, Mihail Popescu, and K.C. Ho. Acoustic fall detection using a circular microphone array. In *Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, pages 2242–2245. Electr. & Comp. Eng. Dept., Univ. of Missouri, Columbia, MO, USA, August 2010.
- 810 [80] Yun Li, K. C. Ho, and Mihail Popescu. A microphone array system for automatic fall detection. *IEEE Transactions on Biomedical Engineering*, 59(5):1291–1301, May 2012.
- [81] Sankar Rangarajan, Assegid Kidane, Gang Qian, Stjepan Rajko, and David Birchfield. The design of a pressure sensing floor for movement-based human computer interaction. In Gerd Kortuem, Joe Finney, Rodger Lea, and Vasughi Sundramoorthy, editors, *Lecture Notes in Computer Science, Smart Sensing and Context*, volume 4793 of *Lecture Notes in Computer Science*, pages 46–61. Springer Berlin Heidelberg, 2007.
- 815 [82] Henry Rimminen, Juha Lindström, Matti Linnavuo, and Raimo Sepponen. Detection of falls among the elderly by a floor sensor using the electric near field. *Information Technology in Biomedicine, IEEE Transactions on*, 14(6):1475–1476, November 2010.
- 820 [83] Arni Ariani, Stephen J. Redmond, David Chang, and Nigel H. Lovell. Software simulation of unobtrusive falls detection at night-time using passive infrared and pressure mat sensors. In *Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, pages 2115–2118. Grad. Sch. of Biomed. Eng., Univ. of New South Wales, Sydney, NSW, Australia, August 2010.
- 825

- [84] Yanbo Tao, Huihuan Qian, Meng Chen, Xin Shi, and Yangsheng Xu. A real-time intelligent shoe system for fall detection. In *IEEE International Conference on Robotics and Biomimetics (ROBIO)*, pages 2253–2258. Dept. of Mech. & Autom. Eng., Chinese Univ. of Hong Kong, Hong Kong, China, December 2011.
- 830 [85] Mihail Popescu, Benjapon Hotrabhavananda, Michael Moore, and Marjorie Skubic. Vampir-an automatic fall detection system using a vertical pir sensor array. In *6th International Conference on Pervasive Computing Technologies for Healthcare (PervasiveHealth)*, pages 163–166. Center for Eldercare & Rehabilitation Technol., Univ. of Missouri, Columbia, MO, USA, May 2012.
- 835 [86] Hamid Medjahed, Dan Istrate, Jerome Boudy, and Bernadette Dorizzi. Human activities of daily living recognition using fuzzy logic for elderly home monitoring. In *IEEE International Conference on Fuzzy Systems*, pages 2001 – 2006. LRIT Lab., ESIGETEL, Avon-Fontainebleau, France, August 2009.
- [87] Edgardo Aviles-Lopez, Ismael Villanueva-Miranda, and Luis E. Palafox-Maestre. Taking
840 care of our elders through augmented spaces. In *Latin American Web Congress*, pages 16–21. Comput. Sci. Dept., CICESE Res. Center, Ensenada, Mexico, November 2009.
- [88] Luca Della Toffola, Shyamal Patel, Bor rong Chen, Yalgin M. Ozsecen, Alessandro Puiatti, and Paolo Bonato. Development of a platform to combine sensor networks and home robots to improve fall detection in the home environment. In *Annual International Conference of the IEEE Engineering in Medicine and Biology Society, EMBC*, pages 5331–5334. Med. Sch.,
845 Dept. of Phys. Med. & Rehabilitation, Harvard Univ., Boston, MA, USA, September 2011.
- [89] Nadia Zouba, Francois Bremond, and Monique Thonnat. An activity monitoring system for real elderly at home: Validation study. In *Seventh IEEE International Conference on Advanced Video and Signal Based Surveillance (AVSS)*, pages 278–285. PULSAR Team,
850 INRIA Sophia-Antipolis Mediterranee, Sophia Antipolis, France, August 2010.
- [90] Oliver Amft and Clemens Lombriser. Modelling of distributed activity recognition in the home environment. In *Annual International Conference of the IEEE Engineering in Medicine and Biology Society, EMBC*, pages 1781–1784. ACTLab, Eindhoven Univ. of Technol., Eindhoven, Netherlands, September 2011.
- 855 [91] Sebastian Chiriac, Bruno Rosales Saurer, Gabi Stummer, and Christophe Kunze. Introducing a low-cost ambient monitoring system for activity recognition. In *5th International Conference on Pervasive Computing Technologies for Healthcare (PervasiveHealth)*, pages 340–345. Embedded Syst. & Sensors Eng. (ESS), FZI Forschungszentrum Inf., Karlsruhe, Germany, May 2011.
- 860 [92] M. Gövercin, Y. Koltzsch, M. Meis, S. Wegel, M. Gietzelt, J. Spehr, S. Winkelbach, M. Marschollek, and E. Steinhagen-Thiessen. Defining the user requirements for wearable and optical fall prediction and fall detection devices for home use. *Informatics for health and social care*, 35(3-4):177–187, September - December 2010.
- [93] Raspberry Pi Foundation. Raspberry pi. Website, March 2012. <http://www.raspberrypi.org/> [zuletzt besucht am 04.04.2013].
865

- [94] Arduino. Arduino Uno. Website. <http://arduino.cc/en/Main/arduinoBoardUno> [zuletzt besucht am 04.04.2013].
- [95] Raspberry Pi Foundation. Raspbian. Website, April 2013. <http://www.raspbian.org/> [zuletzt besucht am 04.04.2013].
- 870 [96] Python Software Foundation. Python. Website, April 2013. <http://www.python.org/> [zuletzt besucht am 04.04.2013].
- [97] Hwaci - Applied Software Research. SQLite. Website, April 2013. <http://www.sqlite.org/> [zuletzt besucht am 04.04.2013].
- 875 [98] Carnegie Mellon University. CMU Sphinx. Website, April 2013. <http://cmusphinx.sourceforge.net/> [zuletzt besucht am 04.04.2013].